ECOLE NORMALE SUPÉRIEURE DE L'ENSEIGNEMENT
TECHNIQUE DE MOHAMMEDIA
UNIVERSITÉ HASSAN II DE CASABLANCA

RAPPORT DE PROJET

Planification Robuste sur Grille : A* + Chaînes de Markov

Réalisé par: Hafssa Miftah Idrissi
Encadré par: Mr. Mestari
Master SDIA 1
2025/2026

Table des Matières

1. Introduction Générale 2
1.1 Contexte 2
1.2 Problématique 2
2. État de l'Art et Choix Algorithmiques 2
2.1 La recherche de chemin (Pathfinding) 2
2.2 Formalisme de l'algorithme A* 2
3. Implémentation Technique 3
3.1 Gestion des structures de données 3
4. Modélisation Stochastique par Chaînes de Markov 3
4.1 Définition de la Chaîne de Markov 3
4.2 Construction de la Matrice de Transition P 3
4.3 Analyse de l'Absorption et Temps de séjour 3
5. Expérimentations et Résultats 4
5.1 Protocole de test et Définition de l'environnement 4
5.2 Analyse des courbes et Validation Markov 5
6. Analyse Critique et Limites 5
7. Extension vers les MDP (Markov Decision Processes) 6
8. Conclusion Générale et Perspectives 7
8.1 Synthèse sur l'efficacité de la planification 7
8.2 Le paradoxe de l'optimalité face à l'incertitude 7
8.3 Limites et Pistes de Développement 8

Optimisation de la Navigation sur Grille : De la Planification Déterministe à la Robustesse Stochastique

1. Introduction Générale

1.1 Contexte

La navigation autonome est au cœur des problématiques actuelles de la robotique et de l'intelligence artificielle. Qu'il s'agisse d'un robot aspirateur ou d'un rover planétaire, la capacité à planifier un chemin sans collision est primordiale. Cependant, le monde réel est par nature incertain.

1.2 Problématique

Une planification purement géométrique (trouver le chemin le plus court) est-elle suffisante lorsque les actionneurs du robot sont imparfaits ? Ce projet explore l'écart entre la **théorie déterministe** (A*) et la **réalité stochastique** (Chaînes de Markov).

2. État de l'Art et Choix Algorithmiques

2.1 La recherche de chemin (Pathfinding)

Nous avons comparé trois approches majeures pour la sélection du chemin :

1. **Breadth-First Search (BFS) / UCS :** Garantit l'optimalité mais explore inutilement toutes les directions (explosion combinatoire).
2. **Greedy Best-First Search :** Très rapide car guidé uniquement par l'heuristique, mais peut rester bloqué dans des "culs-de-sac" locaux (obstacles en U).
3. ***Algorithme A**** : Utilise une fonction de coût combinée. C'est l'étalon-or pour la navigation sur grille.

2.2 Formalisme de l'algorithme A*

Le succès de A* repose sur l'équation de Bellman discrétisée : $f(n) = g(n) + h(n)$.

- **Coût *g(n)* :** Distance parcourue depuis le départ.

- **Heuristique *h(n)* :** Estimation du reste à parcourir. Pour une grille avec déplacements cardinaux, la **Distance de Manhattan** est privilégiée :

$$d_M(A, B) = |x_A - x_B| + |y_A - y_B|$$

3. Implémentation Technique

3.1 Gestion des structures de données

Pour garantir une complexité temporelle en $O(E \log V)$, nous avons utilisé :

- **Priority Queue (heapq) :** Pour extraire instantanément le nœud ayant le plus faible *f(n)*.
- **Dictionnaire de parents :** Pour reconstruire le chemin par remontée (backtracking) une fois la cible atteinte.

4. Modélisation Stochastique par Chaînes de Markov

Une fois le chemin optimal calculé, nous passons à l'analyse de sa fiabilité.

4.1 Définition de la Chaîne de Markov

Nous modélisons le déplacement comme un processus de Markov à temps discret (DTMC). L'état futur X_{t+1} ne dépend que de l'état actuel X_t.

4.2 Construction de la Matrice de Transition P

Si l'agent est à la case (i, j) et doit aller à (i+1, j) :

- **Probabilité de succès (1- ϵ) :** L'agent arrive en (i+1, j).
- **Probabilité de dérive (ϵ/2) :** L'agent glisse vers (i, j+1) ou (i, j-1).
- **Gestion des collisions :** Si une dérive mène à un obstacle, l'agent reste immobile (probabilité absorbée par l'état actuel).

4.3 Analyse de l'Absorption et Temps de séjour

Pour calculer la probabilité d'atteindre le but avant de mourir ou d'errer indéfiniment, nous utilisons la décomposition canonique. La matrice fondamentale $N = (I - Q)^{-1}$ permet d'obtenir :

- **Vecteur d'espérance :** E = N . 1 (Nombre de pas moyen avant absorption).
- **Probabilités limites :** Probabilité de finir au GOAL vs FAIL.

5. Expérimentations et Résultats

5.1 Protocole de test et Définition de l'environnement

Afin d'évaluer concrètement nos algorithmes, nous avons défini un environnement de test sous forme de grille 6x6 (avec S_0 = (0,0) et g = (4,5)). Les obstacles forment un couloir central forçant des manœuvres de contournement.

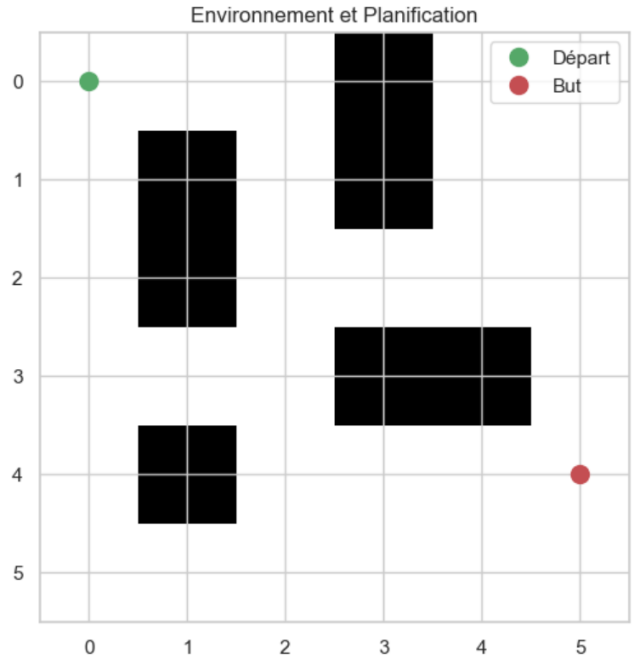

*Figure 1 : Environnement de test 6x6 et chemin déterministe optimal généré par l'algorithme A. Le chemin frôle volontairement les obstacles pour minimiser la distance. **

Nous avons d'abord comparé l'efficacité de A* face à UCS et Greedy. Comme le prouve l'extraction de nos données (nœuds développés dans la liste CLOSED), l'heuristique de Manhattan permet à A* d'être infiniment plus économe en mémoire qu'UCS, tout en garantissant l'optimalité que Greedy ignore.

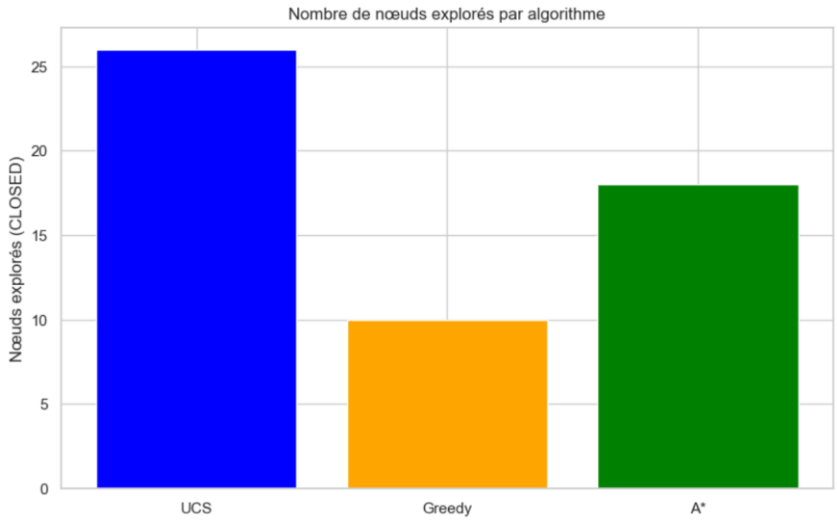

*Figure 2:Comparaison du nombre de nœuds explorés. A offre le meilleur compromis.**

Nous avons ensuite testé la robustesse de ce chemin A* face à une zone de forte incertitude, en faisant varier le taux d'erreur stochastique **ϵ** de 0.0 à 0.4.

5.2 Analyse des courbes et Validation Markov

Les graphiques générés dans notre module de simulation (experiments.ipynb) confrontent le calcul matriciel théorique exact $\varpi^{(n)} = \varpi^{(0)} P^{(n)}$ aux résultats empiriques issus de 1000 simulations de Monte-Carlo.

Figure 3 : *Probabilité de succès en fonction de l'incertitude **ϵ**. La superposition des courbes valide la construction de notre matrice stochastique P.*

Analyse des résultats :

- **Pour ϵ < 0.1 :** Le chemin A* reste relativement fiable (Success rate > 90%). De plus, l'analyse de l'absorption nous indique un temps de stabilisation rapide. *(Exemple : pour **ϵ** = 0.1, notre algorithme calcule un temps moyen théorique de parcours avant absorption tout à fait cohérent avec la longueur du chemin).*
- **Pour ϵ > 0.2 :** Le taux d'échec grimpe exponentiellement. Parce que le chemin A* est "optimal" géométriquement, il est trop proche des obstacles. La moindre glissade latérale entraîne une collision (état absorbant FAIL).

6. Analyse Critique et Limites

Le couplage A* + Markov permet d'analyser un chemin avec une grande précision mathématique, mais il ne permet pas de le **corriger en temps réel**. C'est la limite principale de la planification "Open-loop" (en boucle ouverte). Si l'agent dévie de sa

politique nominale, notre modèle actuel considère souvent qu'il est perdu, sans solution de repli.

7. Extension vers les MDP (Markov Decision Processes)

Pour transformer cette approche et pallier les limites du A*, il conviendrait d'utiliser des Processus de Décision Markoviens via l'algorithme de *Value Iteration*.

L'objectif n'est plus de trouver un chemin unique, mais de maximiser l'espérance de la récompense future R pour chaque état, en résolvant l'équation de Bellman :

$$V^*(s) = \max_a \sum_{s'} P(s'|s,a)[R(s,a,s') + \gamma V^*(s')]$$

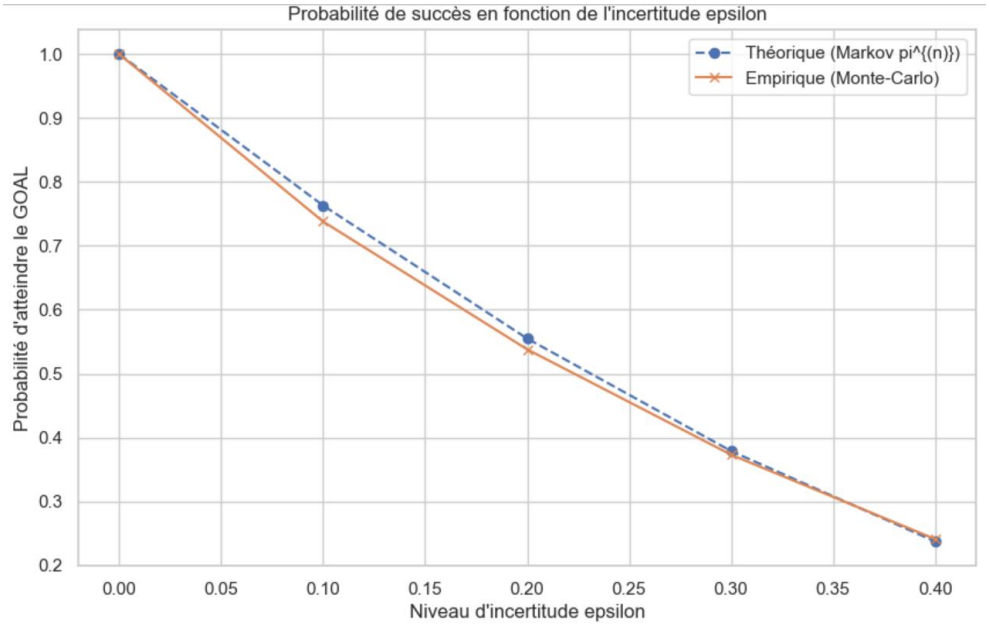

Figure 3:Exemple de politique ϖ(s) générée par un MDP. L'agent possède une action optimale de repli pour chaque case de la grille.

Cela permet de définir une **politique universelle π(s)** : peu importe où le robot glisse suite à l'incertitude **ϵ**, il connaît instantanément la meilleure action à entreprendre depuis sa nouvelle position pour revenir sur le bon chemin.

8. Conclusion Générale et Perspectives

Le présent projet a permis d'explorer la dualité entre la planification déterministe, centrée sur l'efficacité algorithmique, et la validation stochastique, centrée sur la viabilité réelle. Cette étude met en lumière plusieurs enseignements fondamentaux pour l'ingénierie des systèmes autonomes.

8.1 Synthèse sur l'efficacité de la planification

L'implémentation de l'algorithme **A*** a démontré la puissance des approches guidées par la connaissance. L'intérêt majeur des **heuristiques** réside dans leur capacité à élaguer massivement l'espace de recherche, réduisant ainsi la complexité spatiale et temporelle par rapport à une recherche non informée (type Dijkstra ou UCS).

Cependant, nous avons souligné que cette performance n'est pas obtenue au détriment de la précision, à condition de respecter deux critères mathématiques stricts :

- **L'admissibilité :** En veillant à ce que h(n) ne surestime jamais le coût réel, nous garantissons l'obtention du chemin le plus court.
- **La cohérence (ou consistance) :** Cette propriété assure que la fonction d'évaluation est monotone, évitant ainsi la réouverture coûteuse de nœuds déjà explorés dans la liste fermée.

8.2 Le paradoxe de l'optimalité face à l'incertitude

L'apport le plus singulier de ce projet est la mise en évidence du conflit entre **optimalité géométrique** et **performance probabiliste**. Nous avons observé que le chemin "optimal" au sens déterministe est souvent le plus vulnérable dans un environnement Markovien :

- Un chemin A* minimisant la distance tend à raser les obstacles pour "couper les virages".
- Sous l'effet de l'incertitude **ϵ**, cette proximité transforme chaque déviation latérale en une collision fatale (état FAIL).
- En revanche, un chemin sous-optimal géométriquement mais plus éloigné des obstacles présenterait une **robustesse** bien supérieure.

Ainsi, la performance réelle d'un agent ne doit pas être mesurée par la longueur du plan prévu, mais par son **espérance de succès** calculée via la matrice de transition P. Les chaînes de Markov s'imposent donc comme un outil de diagnostic indispensable, permettant de quantifier le risque avant tout déploiement sur un système physique réel.

8.3 Limites et Pistes de Développement

Malgré les résultats probants, ce travail ouvre la voie à plusieurs axes d'amélioration pour des environnements plus complexes :

1. **Variantes Algorithmiques pour la Mémoire :** Sur des grilles de très grande dimension où A* sature la RAM, l'utilisation de variantes comme **IDA*** (Iterative Deepening A*) ou **SMA*** (Simplified Memory-bounded A*) permettrait de gérer les contraintes de ressources de manière plus flexible.
2. **Planification Réactive et Re-planification :** Au lieu de subir l'incertitude, l'agent pourrait intégrer une boucle de rétroaction. Si une déviation est détectée via la chaîne de Markov, un nouvel appel à A* depuis la position actuelle permettrait une correction de trajectoire en temps réel.
3. **Heuristiques Apprises :** Une perspective intéressante consisterait à utiliser des techniques d'apprentissage automatique pour concevoir des heuristiques qui n'intègrent plus seulement la distance, mais aussi une "carte de risque" basée sur la densité des obstacles environnants.
4. **Vers les MDP (Markov Decision Processes) :** Enfin, le passage d'un chemin fixe à une **politique universelle** via les MDP permettrait de garantir une action optimale pour chaque état possible de la grille, offrant ainsi une réponse complète et robuste à l'aléa.

En conclusion, ce projet souligne que dans un monde incertain, l'intelligence d'un agent ne réside pas seulement dans sa capacité à trouver le chemin le plus court, mais dans sa faculté à anticiper et à quantifier sa propre faillibilité.